

Relatório do bootcamp - 3

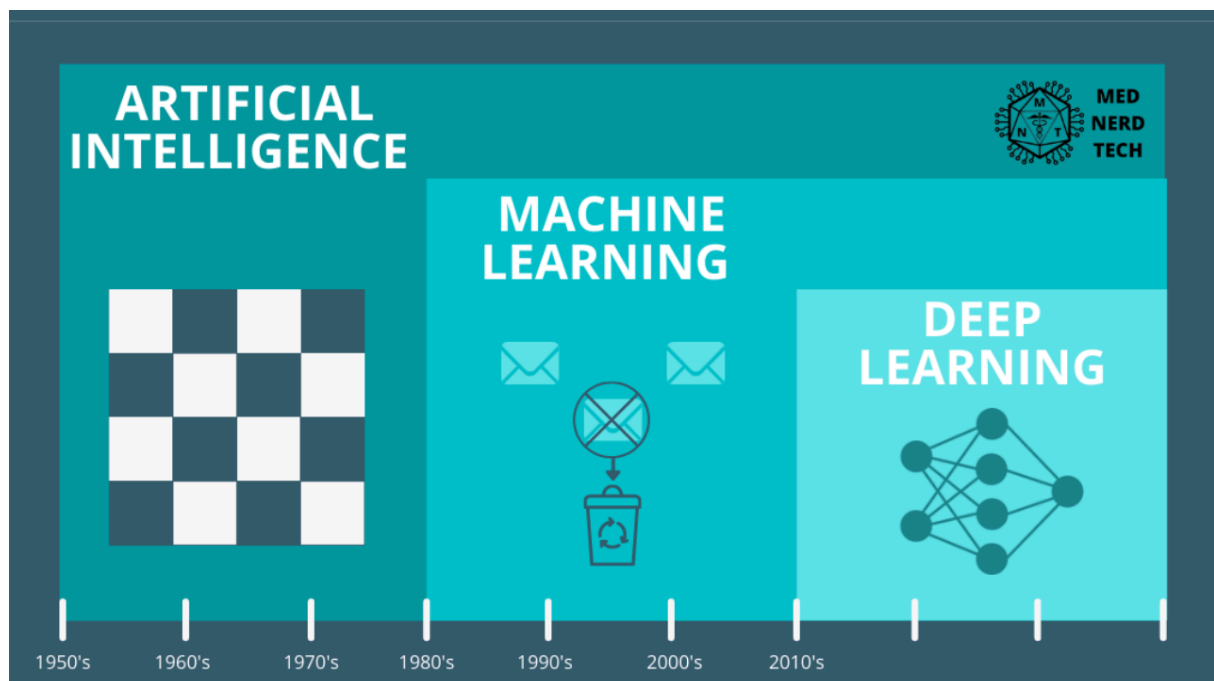
Thassiana C. A. Muller

Inteligência Artificial e Machine Learning

Inteligência artificial (IA) é a semelhança entre a realização de atividades complexas pela máquina e por seres humanos, para que isso seja possível são utilizadas técnicas como, por exemplo, visão computacional, processamento de linguagem natural e machine learning (ML)

Nesse contexto, aprendizado de máquina ou machine learning diz respeito à identificação de regras e padrões em um escopo específico baseado em uma ampla entrada de dados, para isso são utilizados métodos mais simples, como classificação, regressão, agrupamento e associação e alguns métodos mais complexos como a aprendizagem profundo ou deep learning

Observa-se a relação entre alguns dos termos na figura abaixo:



Enquanto a inteligência artificial é capaz de lidar com tarefas diversificadas como a conversação com um ser-humano, ou a direção autônoma de um carro, o aprendizado de máquina se restringe a tarefas mais específicas, como a classificação de emails como spam ou descoberta de padrões de compras em uma loja. Por fim, o deep learning é subcampo do ML que usa técnicas mais robustas de reconhecimento de padrões menos triviais como o reconhecimento de objetos em uma imagem ou uma doença de pele em uma foto.

Aprendizado supervisionado vs não-supervisionado

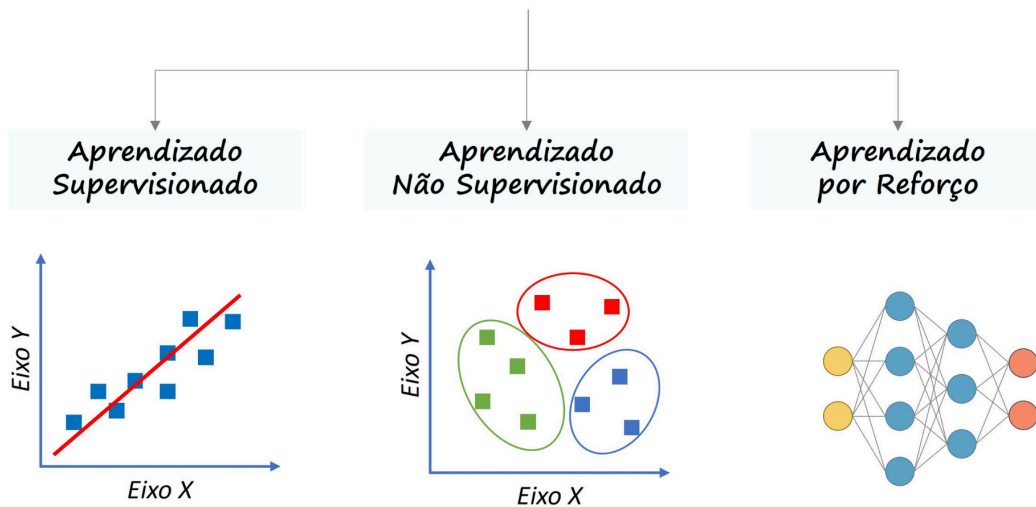
Quando se trata de machine learning, o aprendizado supervisionado é aquele que se treina o algoritmo com dados já rotulados corretamente com a resposta esperada, de forma que o algoritmo passe a encontrar regras que associam as entradas com as saídas desejadas. Problemas comuns que utilizam esse meio de aprendizado são a previsão de preços de imóveis com base em características como localização, tamanho e número de quartos ou a análise de crédito para um cliente de um banco. Para isso, podem ser usados, por exemplo, algoritmos de regressão linear e árvores de decisão..

Já no treinamento não supervisionado, o algoritmo não recebe a resposta esperada das entradas, cabendo a ele, então, descobrir sozinho os padrões nos dados fornecidos. Normalmente, esse tipo de problema visa um agrupamento ou clusterização dos dados de forma a obter insights e resumos sobre um grande número de informações. Os problemas comuns que essa técnica engloba são a detecção de anomalias em conjuntos de dados a fim de identificar atividades suspeitas ou eventos incomuns, a redução de dimensionalidade para simplificar conjuntos de dados complexos, a melhoria na visualização e análise de documentos ou notícias, e a recomendação de produtos baseando-se em padrões de compra do usuário. Técnicas populares de aprendizado não supervisionado incluem algoritmos como k-means, clustering hierárquico, análise de componentes principais (PCA) e mapas auto-organizáveis (SOM).

Aprendizado por reforço

A aprendizagem por reforço é a técnica de machine learning que recebe feedbacks a cada interação com seu contexto de aprendizagem, permitindo que o programa ou “robô” aprenda a tomar decisões de modo a maximizar suas “recompensas” ao longo do tempo. Através desse processo de tentativa e erro, o robô desenvolve uma política que define a melhor ação a ser tomada em cada estado para alcançar seus objetivos. Problemas comuns que utilizam a aprendizagem por reforço incluem o treinamento de robôs para realizar tarefas específicas, como caminhar ou pegar objetos, a otimização de estratégias em jogos como xadrez e o controle de sistemas dinâmicos, como redes de tráfego e sistemas de recomendação personalizados. Algoritmos populares de aprendizagem por reforço incluem Q-learning, SARSA, e métodos baseados em políticas como o Proximal Policy Optimization (PPO) e o Deep Q-Network (DQN).

TIPOS DE APRENDIZADO DE MACHINE LEARNING



Desafios da IA e ML

Atualmente, os maiores desafios encontrados são:

- A disponibilidade e qualidade dos dados, já que coletar dados relevantes e suficientes pode ser difícil devido a restrições de privacidade e confiabilidade das fontes;
- O overfitting onde o modelo fica muito complexo e realiza apenas as tarefas a qual foi exposto, não sendo capaz de extrapolar sua capacidade;
- O underfitting que é quando o modelo não é suficientemente preciso, a interpretabilidade dos modelos que, principalmente no deep learning, se tornam obscuros ao entendimento humano e afetam aplicações críticas como a área médica, onde é crucial entender as decisões do modelo;
- E a escalabilidade, que envolve garantir a eficiência dos algoritmos em grandes volumes de dados à medida que os conjuntos de dados e modelos crescem.

Bibliografia

- <https://www.dataviking.com.br/post/tipos-de-aprendizado-em-machine-learn>
- [Inteligência Artificial vs Machine Learning vs Deep Learning | mednerdtech](#)
- <https://cloud.google.com/learn/artificial-intelligence-vs-machine-learning?hl=pt-br>
- <https://www.linkedin.com/pulse/intelig%C3%Aancia-artificial-e-aprendizado-de-m%C3%A1quina-rela%C3%A7%C3%A3o-monjane/>

